# Premier League Match Recommender

Diseño de Arquitectura Híbrida: Procesamiento de Lenguaje Natural (PLN) + Analítica Numérica

**Dominio:** Deportes / Premier League | **Enfoque:** Hybrid Multi-modal ML | **Casos de Uso:** Recomendar Partidos Épicos / Hype / Tácticos

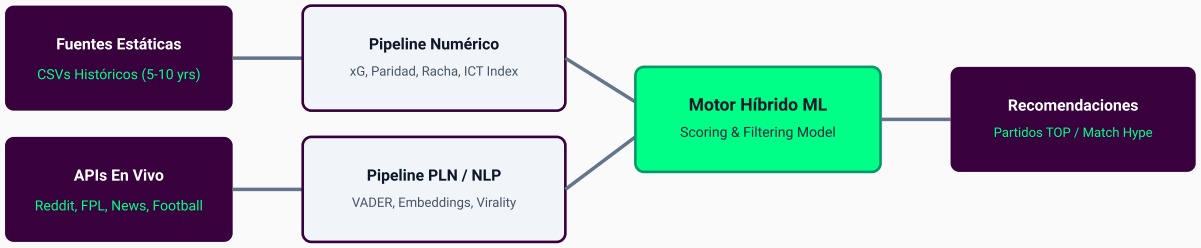
## 1. RESUMEN EJECUTIVO Y VISIÓN DEL SISTEMA

Visión General

A diferencia de las plataformas estáticas de streaming, recomendar eventos deportivos en vivo o futuros requiere evaluar el **potencial de espectáculo (Excitement Score)** antes de que ocurra el evento. Este proyecto diseña un motor híbrido que combina métricas estadísticas objetivas ($xG$, posición en tabla, intensidad táctica) con señales cualitativas extraídas de la afición y prensa (sentimiento en Reddit, cobertura mediática y narrativas históricas) para clasificar y recomendar partidos de la Premier League.

## 2. DIAGRAMA DE ARQUITECTURA MULTIMODAL

Flujo de Datos




## 3. CATÁLOGO DE ARCHIVOS DATASET (CSVS HISTÓRICOS)

Datos Offline

| Archivo CSV | Fuente de Origen | Variables Contenidas | Propósito |
|---|---|---|---|
| `EPL_Matches_10Y.csv` | Football-Data.co.uk | Goles, Tiros al arco, Córners, Faltas, Tarjetas, Odds de Apuestas. | Entrenar modelo base de probabilidad de goles y volatilidad. |
| `EPL_Advanced_Stats.csv` | FBref (vía `soccerdata`) | Goles Esperados ($xG$), $xGA$, Pases Progresivos, Presión Alta, SCA. | Definir perfil e intensidad táctica de cada club. |
| `EPL_Commentaries.csv` | Kaggle / ESPN Dataset | Narración textual minuto a minuto de partidos históricos. | Entrenar clasificadores NLP para calificar "Partidos Dramáticos". |
| `EPL_FPL_Historical.csv` | Fantasy Premier League API | Índice ICT (Influence, Creativity, Threat), puntos por partido. | Medir la relevancia y forma individual de jugadores |

## 4. INTEGRACIÓN DE APIS EN TIEMPO REAL

Datos Online

Para calificar los partidos de la próxima jornada, el sistema consulta 4 APIs estratégicas que capturan la coyuntura del momento, lesiones de última hora y el volumen de conversación de la afición.

| API Service | Endpoints / Métodos | Información Extraída | Frecuencia |
|---|---|---|---|
| **API-Football** `RapidAPI` | `/fixtures` `/standings` `/lineups` | Calendario oficial, posiciones actuales en tabla, alineaciones confirmadas, lesionados. | Diaria / Cada 15 min en jornada |
| **Reddit API** `PRAW Python` | `r/soccer` `r/PremierLeague` | Hilos *Pre-Match* y *Match Threads*: volumen de comentarios, karma y velocidad. | En tiempo real (30 min) |
| **Official FPL API** | `/bootstrap-static/` `/element-summary/` | Popularidad de jugadores (% de selección), estado físico, índice ICT actualizado. | Semanal / Pre-jornada |
| **News API / GNews** | `/v2/everything` | Noticias pre-partido, declaraciones de entrenadores, tensión previa por derbis. | Diario |

## 5. ARQUITECTURA DEL PIPELINE PLN (PROCESAMIENTO DE LENGUAJE NATURAL)

NLP Core

El módulo de PLN convierte texto no estructurado en métricas numéricas comparables mediante tres componentes principales:

### A. Análisis de Sentimiento y Hype (Reddit)

A través de **VADER / RoBERTa**, procesamos los comentarios de Reddit pre-partido. Calculamos la densidad de comentarios por minuto y la polaridad emocional para medir la expectativa real de la afición.

### B. Embeddings de Narrativas Tácticas

Utilizando **Sentence-Transformers** en los reportes de prensa y noticias, generamos vectores que detectan conceptos clave como *"lucha por el título"*, *"zona de descenso"* o *"clásico de alta rivalidad"*.

### C. Clasificador de Dramatismo (Commentary)

Un modelo entrenado con descripciones de texto histórico (ej. *"gol agónico en el 94'"*, *"remontada imprevista"*) asigna una probabilidad de dramatismo según el estilo narrativo que suele generar el cruce.

### D. Índice de Tensión Mediática (Media Velocity)

Se calcula la aceleración del número de artículos publicados respecto a la media de la temporada. Un pico inusual de noticias indica un partido de alta trascendencia nacional.

## 6. ALGORITMOS PLN SELECCIONADOS

Técnicas

| Técnica PLN | Librería / Modelo Base | Entrada | Métrica Generada |
|---|---|---|---|
| Análisis de Polaridad | `NLTK VADER` / `TextBlob` | Comentarios en Reddit | `Fan_Excitement_Index` (0-100) |
| Embeddings Semánticos | `all-MiniLM-L6-v2` | Titulares de Noticias | `Context_Relevance_Vector` |
| TF-IDF + Cosine Similarity | `scikit-learn` | Histórico Narrativo | `Derby_Rivalry_Score` (0-1) |

## 7. MÉTRICAS NUMÉRICAS Y ESTADÍSTICAS TÁCTICAS

Features

Paralelamente al análisis de texto, se extraen y calculan indicadores numéricos avanzados para cuantificar la calidad futbolística proyectada del encuentro.

| Métrica Numérica | Fórmula / Lógica | Significado en la Recomendación |
|---|---|---|
| **Expected Goals Combined ($xG_{comb}$)** | $xG_{Local} + xG_{Visitante}$ (Últimos 5 partidos) | Proyección del volumen de ataques e intensidad ofensiva. |
| **Índice de Paridad de Tabla** | $1 - \frac{\|Pos_{Local} - Pos_{Visitante}\|}{20}$ | A mayor cercanía en la tabla, mayor es lo que está en juego. |
| **Estilo Táctico Operativo** | $Similitud(Pases_{Progresivos}, Presiones)$ | Identifica choques estilo "Ataque vs Ataque" o "Contraataque". |
| **Star Player Availability** | $\sum ICT_Index$ de alineación titular | Garantiza que figuras decisivas (ej. Haaland, Saka) estén presentes. |

## 8. FORMULACIÓN MATEMÁTICA DEL RECOMENDADOR

Scoring Model

El algoritmo combina las métricas de PLN y numéricas en una puntuación final ponderada ($Score_{\text{partido}}$):

$$\text{Score}_{\text{partido}} = w_1(xG_{comb}) + w_2(\text{Paridad}) + w_3(\text{Fan_Excitement_Index}) + w_4(\text{Media_Velocity})$$

## 9. STACK TECNOLÓGICO DE LIBRERÍAS PYTHON

Librerías

| Categoría | Librería / Herramienta | Uso Principal en el Proyecto |
|---|---|---|
| **Extracción de Datos** | `requests`, `praw`, `soccerdata`, `understat` | Consumo de APIs de Reddit, Football Data y extracción de xG. |
| **Procesamiento PLN** | `nltk`, `spacy`, `transformers`, `textblob` | Limpieza de texto, tokenización, análisis de sentimientos y embeddings. |
| **Manipulación & ML** | `pandas`, `numpy`, `scikit-learn`, `xgboost` | Ingeniería de características, normalización y modelo de scoring. |
| **Backend & Serving** | `fastapi`, `pydantic`, `uvicorn` | Creación de la API para servir las recomendaciones recomendadas. |

## 10. PLAN DE IMPLEMENTACIÓN POR FASES

Roadmap

**Fase 1: Ingesta & Dataset**

Descarga de CSVs de Football-Data y FBref. Configuración de credenciales de PRAW (Reddit API) y API-Football.

**Fase 2: Pipeline PLN**

Construcción de scripts en Python para extraer comentarios de Reddit pre-partido y procesar sentimiento con VADER.

**Fase 3: Modelo Híbrido**

Unificación de variables estadísticas con métricas de PLN. Ajuste de pesos $w_1, w_2, w_3, w_4$ con validación cruzada.

**Fase 4: API & Recomendador**

Despliegue de servicio en FastAPI que recibe una fecha de la jornada y devuelve los 3 partidos recomendados con sus justificantes.